

SSAFY-T+

SSAFY-T+: Extended Surprise-Sensitive Adaptive Framework for Your Answers with Titans

1. Overview

SSAFY-T+는 기존 SSAFY-T를 확장한 고성능 Visual Question Answering(VQA) framework이다.

기존 SSAFY-T가 다음 요소를 중심으로 구성되었다면,

```
Qwen3-VL
+
4-bit QLoRA
+
Direct 4-choice CE
+
Hard-negative margin
+
Surprise Replay
+
Pseudo-label learning
+
Adaptive second-pass inference
```

SSAFY-T+는 여기에 다음 요소를 추가한다.

1. Qwen3-VL-2B와 Qwen3-VL-4B의 dual-model ensemble
2. Language LoRA + Vision LoRA
3. Random option permutation training
4. Multi-permutation inference ensemble
5. Weak image augmentation
6. Semantic Candidate Scorer
7. Letter score와 semantic score의 validation-calibrated fusion
8. Validation 기반 2B/4B ensemble weight calibration

9. Gold training data 100% final retraining

10. Validation과 final training phase의 명시적 분리

SSAFY-T+의 핵심 목적은 단순히 모델의 크기를 키우는 것이 아니다.

기존 SSAFY-T에서 남아 있던 다음 문제를 각각 다른 mechanism으로 보완한다.

```
선지 위치 bias
→ Option Permutation

Visual domain mismatch
→ Vision LoRA

Single-model error
→ 2B/4B Ensemble

Letter-token dependency
→ Semantic Candidate Scorer


Small training data
→ Image Augmentation


Validation holdout 손실
→ Final Gold 100% Retraining
```

따라서 SSAFY-T+는 SSAFY-T의 adaptive learning philosophy를 유지하면서, **representation diversity, prediction diversity, semantic verification, data efficiency**를 동시에 강화한 architecture이다.

2. Evolution of the SSAFY Architecture

SSAFY 계열의 발전 과정은 크게 세 단계로 볼 수 있다.





SSAFY가 efficient baseline이라면 SSAFY-T는 adaptive learning framework이고, SSAFY-T+는 이를 **multi-view and multi-model decision framework**로 확장한 모델이다.

3. Problem Definition

각 sample은 이미지, 질문, 네 개의 선택지로 구성된다.

$$x_i = (I_i, Q_i, O_i)$$

여기서 O_i 는 네 개의 선택지 집합이다.

모델의 목표는 최종적으로 **a**, **b**, **c**, **d** 중 하나를 선택하는 것이다.

SSAFY-T+는 이 문제를 하나의 classifier로만 해결하지 않는다.

동일한 문제를 다음 여러 관점에서 평가한다.

```
Letter-level scoring
Option permutation scoring
Semantic candidate verification
Low-resolution inference
High-resolution inference
2B model inference
4B model inference
```

이 여러 prediction signal을 validation에서 calibration한 뒤 최종 decision에 결합한다.


4. Dual-Model Architecture

SSAFY-T+는 두 개의 Qwen3-VL backbone을 사용한다.

Qwen3-VL-2B-Instruct
Qwen3-VL-4B-Instruct

두 모델은 동시에 GPU memory에 올리지 않는다.

대신 순차적으로 학습한다.



이 구조를 통해 single GPU 환경에서도 서로 다른 parameter scale의 모델을 ensemble 할 수 있다.

5. Why 2B and 4B Are Used Together

모델 크기가 크다고 해서 모든 sample에서 항상 더 좋은 prediction을 한다고 가정하지 않는다.

2B model은 상대적으로 작은 capacity를 가지지만 다음 장점이 있다.

빠른 학습
빠른 inference
낮은 VRAM 사용량
상대적으로 단순한 decision boundary

4B model은 다음 장점을 가진다.

높은 representation capacity
복잡한 visual-language 관계 처리

두 모델의 오류 패턴이 완전히 동일하지 않다면 ensemble을 통해 single-model error를 줄일 수 있다.

SSAFY-T+는 validation에서 2B와 4B의 가중치를 직접 탐색한다.

최종 score는 개념적으로

$$S = wS_{2B} + (1 - w)S_{4B}$$

형태로 계산된다.

w 는 validation accuracy가 최대가 되는 값으로 선택된다.

6. Sequential GPU Strategy

2B와 4B 모델을 동시에 GPU에 배치하면 VRAM 요구량이 크게 증가한다.

SSAFY-T+에서는 다음 sequence를 사용한다.

```
Load 2B
↓
Training / Validation / Prediction
↓
Save logits to CPU
↓
Delete model
↓
gc.collect()
↓
torch.cuda.empty_cache()
↓
Load 4B
```

따라서 ensemble을 사용하면서도 동시에 두 large multimodal models를 GPU에 유지할 필요가 없다.

이 설계는 특히 24GB 단일 GPU와 같은 제한된 환경에서 중요하다.

7. 4-bit NF4 QLoRA

두 모델 모두 4-bit NF4 quantization을 사용한다.

```
load_in_4bit          = True
double quantization    = True
quantization type      = NF4
```

Backbone weight는 quantized 상태로 유지되고 LoRA adapter parameter만 학습된다.

SSAFY-T+에서도 LoRA 설정은 다음과 같다.

```
rank      = 8
alpha     = 16
dropout   = 0.05
```

따라서 full fine-tuning과 비교해 optimizer state와 GPU memory 요구량을 크게 줄인다.

8. Vision LoRA

SSAFY-T와 SSAFY-T+의 중요한 차이 중 하나는 **Vision LoRA**이다.

기존 SSAFY-T에서는 `vision` 또는 `visual` 이라는 이름이 포함된 module을 LoRA target 에서 완전히 제외하였다.

SSAFY-T+에서는 language module뿐 아니라 **vision encoder의 마지막 일부 block도 adaptation 대상으로** 사용한다.

현재 설정에서는 각 model의 마지막 4개 vision block을 선택한다.

```
Vision Encoder
|
├── Early Blocks
│   └── Frozen
└── Last 4 Blocks
    └── Vision LoRA
```

9. Why Only the Last Vision Blocks Are Adapted

Vision backbone 전체를 fine-tuning하면 표현 능력을 크게 바꿀 수 있지만 다음 문제가 발생한다.

```
VRAM 증가
training instability
small dataset overfitting
pretrained visual representation 손상
```

반대로 vision encoder를 완전히 freeze하면 recycling image domain에 특화된 visual feature를 학습하기 어렵다.

SSAFY-T+는 이 두 극단 사이의 절충안으로 **late-stage visual adaptation**을 사용한다.

초기 vision block은 일반적인 edge, texture, shape representation을 유지하고, 마지막 block만 domain-specific visual semantics에 적응하도록 한다.

10. Separate Learning Rates for Vision and Language

Vision LoRA와 Language LoRA에는 동일한 learning rate를 사용하지 않는다.

예를 들어 2B model은 다음과 같다.

```
Language LR = 1e-4
Vision LR   = 1e-5
```

즉 visual representation은 language representation보다 더 보수적으로 update한다.

4B model 역시 동일한 원칙을 사용한다.

```
Language LR > Vision LR
```

이는 pretrained visual feature를 지나치게 크게 변경하지 않으면서 domain adaptation 효과를 얻기 위한 설계이다.

11. Direct Four-Choice Objective

SSAFY-T의 핵심 objective는 SSAFY-T+에서도 유지된다.

모델이 생성하는 전체 vocabulary logits 중

```
a
b
c
d
```

에 해당하는 token logits만 추출한다.

결과적으로 모델은 네 개의 score만 비교한다.

```
[a_score, b_score, c_score, d_score]
```

Training에서는 4-choice Cross Entropy를 적용하며 inference에서도 동일한 네 score 중 가장 높은 값을 선택한다.

따라서 training과 inference의 decision space가 동일하다.

12. Hard-Negative Margin Loss

SSAFY-T+는 단순히 정답의 probability를 높이는 것에 그치지 않는다.

정답과 가장 높은 오답 사이에 일정한 margin을 형성하도록 한다.

예를 들어

```
Gold = b

a = 4.8
b = 4.9
c = 0.2
d = 0.1
```

이면 prediction 자체는 정답이다.

하지만 **b**와 **a**의 차이가 매우 작기 때문에 decision은 불안정하다.

Hard-negative margin loss는 이러한 sample을 추가로 penalize한다.

전체 loss는 개념적으로 다음 두 요소의 조합이다.

```
4-Choice Cross Entropy
+
0.2 × Hard-Negative Margin Loss
```


13. Surprise Replay

Titans-inspired Surprise Replay 역시 SSAFY-T+에 그대로 유지된다.

각 training sample은 CE loss를 기반으로 surprise score를 가진다.

Surprise score는 EMA 방식으로 업데이트한다.

높은 loss가 지속되는 sample일수록 높은 surprise를 유지한다.

Replay sampling probability는 이 surprise score에 비례한다.

현재 한 epoch에서는 기본 training data에 약 25%의 replay sample이 추가된다.

100% Original Samples
+
25% Surprise-weighted Replay

따라서 모델이 계속 틀리는 sample을 더 자주 학습한다.

14. Random Option Permutation Training

SSAFY-T+에서 새롭게 추가된 중요한 기능이다.

일반적인 multiple-choice dataset에서는 선택지 위치가 고정되어 있다.

(a) ...
(b) ...
(c) ...
(d) ...

모델이 충분히 많은 데이터를 학습하면 실제 선택지 의미뿐 아니라 특정 letter position에 대한 bias를 학습할 수 있다.

이를 방지하기 위해 SSAFY-T+는 training sample을 불러올 때 선택지 순서를 랜덤하게 재배치한다.

예를 들어 원래 문제가

(a) 캔
(b) 종이
(c) 플라스틱 ← 정답
(d) 유리

였다면 training 과정에서는

- (a) 유리
- (b) 플라스틱 ← 정답
- (c) 캔
- (d) 종이

처럼 변경될 수 있다.

이때 gold label도 자동으로 **c → b** 로 변경된다.

15. Why Option Permutation Matters

Option permutation의 목적은 모델에게 다음 shortcut을 허용하지 않는 것이다.

"이 종류의 문제는 c가 자주 정답이다."

대신 모델이 다음 관계를 학습하도록 강제한다.

```
Image
+
Question
+
Actual semantic content of choice
```

즉 letter가 아니라 **선지 자체의 의미**를 기반으로 prediction하도록 한다.

Training에서는 기본적으로 모든 sample에 permutation을 적용하도록 설정되어 있다.

16. Multi-Permutation Inference

Option permutation은 training에만 사용되지 않는다.


Inference에서도 동일한 문제를 여러 선택지 배열로 평가한다.

현재 네 개의 cyclic permutation을 사용한다.

```
a b c d
b c d a
c d a b
d a b c
```

각 permutation에서 얻은 score는 원래 선택지 순서로 복구한다.

그 뒤 네 결과의 log-probability를 평균한다.



이를 통해 특정 letter 위치에 따른 inference bias를 감소시킨다.

17. Validation-Based Permutation Selection

Permutation ensemble이 항상 성능을 개선한다고 가정하지 않는다.

각 model에 대해 validation에서 다음 두 결과를 비교한다.

Identity inference
vs
Permutation ensemble inference

Permutation accuracy가 identity accuracy 이상일 경우에만 final inference에 permutation을 사용한다.

따라서 SSAFY-T+의 augmentation이나 ensemble mechanism은 모두 **validation을 통해 실제 효용이 확인된 경우에만 채택되는** 구조이다.

18. Weak Image Augmentation

SSAFY-T+는 training 단계에서만 약한 image augmentation을 적용한다.

전체 sample 중 약 70%에서 augmentation pipeline을 활성화한다.

사용되는 augmentation은 다음과 같다.

Brightness variation
Contrast variation
Tiny crop

JPEG compression
Weak Gaussian blur

Validation과 test에는 augmentation을 적용하지 않는다.

19. Brightness and Contrast Augmentation

Brightness와 contrast는 각각 약한 범위에서 변경한다.

Brightness factor:
0.94 ~ 1.06

Contrast factor:
0.94 ~ 1.06

변화 폭이 작기 때문에 이미지의 semantic identity를 유지하면서도 촬영 환경의 조명 차이에 대한 robustness를 증가시킨다.

20. Question-Aware Augmentation

SSAFY-T+에서는 모든 augmentation을 무조건 동일하게 적용하지 않는다.

질문의 의미를 분석하여 augmentation probability를 조정한다.

예를 들어 질문에 다음 키워드가 포함되어 있으면

색
색상
무슨 색
color

brightness와 contrast augmentation probability를 크게 낮춘다.

그 이유는 색상이 실제 정답 결정에 중요한 question에서 color-related augmentation이 label semantics를 변경할 수 있기 때문이다.

21. Spatial-Sensitive Augmentation

다음과 같은 질문에서는 crop augmentation을 사용하지 않는다.

왼쪽
오른쪽
위쪽
아래쪽
몇 개
개수
수량
left
right
how many

예를 들어

"사진 왼쪽에 있는 물체는 무엇인가?"

라는 질문에 crop을 적용하면 실제 문제 자체를 바꿀 수 있다.

따라서 SSAFY-T+는 question type에 따라 augmentation을 제한하는 **semantic-preserving augmentation policy**를 사용한다.

22. Tiny Crop

Crop은 매우 작은 범위에서만 수행한다.

최대 crop 비율은 각 image border의 약 3%이다.

Crop 이후 원래 해상도로 bicubic resize한다.

이는 object를 크게 제거하지 않으면서 촬영 위치나 framing에 대한 minor variation을 생성하기 위한 augmentation이다.

23. JPEG Noise

실제 사용자 이미지에는 JPEG compression artifact가 존재할 수 있다.

SSAFY-T+에서는 training image를 일시적으로 JPEG로 다시 encoding하여 약한 compression noise를 생성한다.

JPEG quality는

90 ~ 98

범위로 제한한다.

따라서 이미지 구조는 유지하면서 실제 촬영 및 업로드 환경과 유사한 noise를 추가한다.

24. Weak Blur

일부 training image에는 매우 약한 Gaussian blur를 적용한다.

Blur radius는


0.10 ~ 0.55

범위이다.

이를 통해 camera focus 차이나 작은 motion blur에 대한 robustness를 높인다.

25. Combined Training Augmentation

하나의 training sample은 대략 다음 pipeline을 통과할 수 있다.



이 설계의 목적은 aggressive data augmentation이 아니라 **label-preserving visual diversity** 증가이다.

26. Semantic Candidate Scorer

SSAFY-T+의 중요한 확장 중 하나는 **Semantic Candidate Scorer**이다.

기존 SSAFY-T는 최종적으로 **a**, **b**, **c**, **d** letter token의 score만 비교한다.

SSAFY-T+는 실제 선택지의 text 자체도 별도의 방식으로 검증한다.

예를 들어

```
Question:
사진 속 용기는 어떤 재질인가?

Candidate answer:
플라스틱
```

이라는 형태의 prompt를 모델에 입력한다.

모델에게 다음과 같이 질문한다.

```
Is this candidate the correct answer
according to the image?
```

그리고 model의

```
yes
no
```

token score를 비교한다.

27. Semantic Verification

네 개의 선택지 각각을 독립적으로 검증한다.

```
Candidate A → yes/no
Candidate B → yes/no
```

```
Candidate C → yes/no  
Candidate D → yes/no
```

각 candidate에 대한 **yes** likelihood를 얻은 뒤 네 candidate 사이에서 다시 normalize 한다.

결과적으로 semantic scorer도 네 개의 score를 생성한다.

```
Semantic A  
Semantic B  
Semantic C  
Semantic D
```

이 방식은 letter position과 독립적으로 실제 선택지 의미를 평가한다는 장점이 있다.

28. Letter Score vs Semantic Score

SSAFY-T+에는 두 개의 서로 다른 scoring mechanism이 존재한다.

Letter Scorer

```
Image  
+  
Question  
+  
Four Options  
↓  
Which letter is correct?  
↓  
a / b / c / d
```

Semantic Scorer

```
Image  
+  
Question  
+  
One Candidate Text  
↓  
Is this candidate correct?  
↓  
yes / no
```


Letter scorer는 네 후보를 동시에 비교하는 데 강점이 있다.

Semantic scorer는 특정 후보의 실제 의미가 visual evidence와 일치하는지를 직접 검증한다.

두 scorer가 서로 다른 failure mode를 가질 수 있기 때문에 ensemble 효과를 기대할 수 있다.

29. Semantic Score Calibration

Semantic scorer의 결과를 무조건 동일한 비율로 사용하지 않는다.

Validation에서 다음 weight를 탐색한다.

```
0.00
0.05
0.10
...
0.50
```

최종 model score는 개념적으로

$$S = (1 - \alpha)S_{\text{letter}} + \alpha S_{\text{semantic}}$$

형태이다.

Validation accuracy가 가장 높은 α 를 선택한다.

만약 semantic scorer가 도움이 되지 않는다면

```
semantic weight = 0
```

이 자동으로 선택될 수 있다.

즉 semantic scorer는 optional auxiliary expert로 동작한다.

30. Adaptive High-Resolution Second Pass

SSAFY-T의 second-pass mechanism도 유지된다.

첫 inference는 비교적 낮은 resolution으로 수행한다.

LOW:
224×224 ~ 448×448 pixel budget

모델의 top-1과 top-2 score 차이가 작은 sample을 uncertainty sample로 간주한다.
이 sample만 고해상도로 다시 inference한다.

HIGH:
256×28×28 ~ 768×28×28 pixel budget

31. Candidate-Focused Reinspection

Second pass에서는 단순히 해상도만 높이지 않는다.
First pass의 top-2 candidate를 prompt에 명시한다.
예를 들어 first pass가 **b**와 **d** 사이에서 불확실했다면

Compare options b and d especially carefully.
Inspect the image again.

이라는 instruction을 추가한다.
따라서 second pass는 다음 두 요소를 결합한다.

Higher visual resolution
+
Focused candidate comparison

32. Second-Pass Threshold Calibration

Second pass를 실행할 confidence threshold는 validation에서 결정한다.
여러 threshold를 시험한다.

0.00
0.10
0.25
0.50
0.75

```
1.00
1.50
2.00
```

Validation accuracy가 최대가 되는 threshold를 선택한다.

이 값을 final test에서도 그대로 사용한다.

33. Human/Teacher Pseudo-Label Learning

SSAFY-T의 pseudo-label Stage 2 역시 유지된다.

Dev sample은 다섯 개의 인간 응답을 가진다.

다음 조건을 모두 만족하는 sample만 pseudo-label로 사용한다.

```
Human agreement >= 80%
AND
Teacher prediction = Human majority
AND
Teacher confidence margin >= 1.0
```

이를 통해 noisy dev labels가 학습에 직접 유입되는 것을 방지한다.

34. Weighted Pseudo Learning

Pseudo sample의 loss weight는 gold sample보다 낮게 설정한다.

```
Gold:
weight = 1.0

Pseudo:
weight = 0.5 × human confidence
```

예를 들어

```
5/5 agreement
→ weight 0.50
```

4/5 agreement
→ weight 0.40

이다.

Pseudo stage에서는 base learning rate에도 추가 factor를 적용한다.

Pseudo LR = Base LR × 0.20

따라서 Stage 2는 conservative refinement 단계로 동작한다.

35. Development Phase

SSAFY-T+는 전체 pipeline을 명확하게 두 단계로 분리한다.

첫 번째는 **Development / Tuning Phase**이다.

Gold Data
├── 90% Training
└── 10% Validation

각 2B/4B model에 대해 validation을 사용하여 다음 항목을 결정한다.

Best Stage1 epoch
Best pseudo epoch
Permutation 사용 여부
Second-pass threshold
Semantic score weight

그 이후 두 model의 validation logits를 이용해

2B / 4B ensemble weight

까지 결정한다.

36. Why Validation Is Used Only for Calibration

SSAFY-T+에서 validation set의 역할은 model parameter를 직접 학습시키는 것이 아니라 **configuration selection**이다.

Validation에서 결정되는 요소는 다음과 같다.

```
When to stop
Whether pseudo stage helps
Whether permutation helps
When to trigger second pass
How much semantic score to trust
How much 2B vs 4B to trust
```

모든 설정이 확정되면 validation set의 역할은 종료된다.

37. Final Gold 100% Retraining

SSAFY-T+의 핵심적인 추가 단계이다.

Development phase에서는 gold data의 10%를 validation으로 사용하기 때문에 실제 학습에는 90%만 사용된다.

모든 hyperparameter가 확정된 뒤에는 pretrained model을 다시 처음부터 load한다.

그 뒤 기존 validation 10%까지 포함한 ****gold data 100%****를 이용해 최종 model을 다시 training한다.

```
Development

Gold 90%
→ Training

Gold 10%
→ Validation

↓

All settings fixed

↓

Final Training
```

```
Gold 100%
→ Retrain from pretrained model
```

38. Why This Is Not Data Leakage

Final retraining 이후에는 기존 validation set의 accuracy를 다시 측정하지 않는다.

즉 validation은 이미 hyperparameter selection이라는 역할을 끝낸 상태이다.

Final stage에서는

```
Gold 100%
↓
Final Model
↓
Test Inference
```

로 바로 진행한다.

따라서 기존 holdout data를 final supervised dataset에 다시 포함하되, 해당 data를 더 이상 evaluation signal로 사용하지 않는다.

39. Preserving the Selected Training Duration

Final retraining에서 epoch 수를 다시 validation으로 탐색하지 않는다.

Development phase에서 선택된 best epoch을 그대로 사용한다.

예를 들어

```
2B best epoch = 6
4B best epoch = 4
```

였다면 final stage에서도 각각 해당 epoch 수를 사용한다.

Pseudo stage 역시 development phase에서 실제 성능 향상이 확인된 경우에만 동일한 epoch 수를 final training에 적용한다.

40. No Validation After Final Retraining

SSAFY-T+ 코드에는 final retraining 이후 validation을 다시 사용하지 않는 경계가 명시적으로 존재한다.

개념적으로 다음과 같다.

```
=====
DEVELOPMENT BOUNDARY
=====

Validation tuning 종료
      ↓

=====
FINAL TRAINING
=====

Gold 100%
+
Selected Pseudo Data
      ↓
Test
```

이를 통해 final gold retraining 후의 training accuracy나 기존 holdout accuracy를 generalization estimate로 오해하는 것을 방지한다.

41. Final 2B and 4B Retraining

2B와 4B 모두 각각 full gold dataset으로 다시 학습된다.


```
Qwen3-VL-2B pretrained
      ↓
100% Gold
      ↓
Selected Pseudo Stage
      ↓
Final 2B logits

Qwen3-VL-4B pretrained
      ↓
100% Gold
      ↓
Selected Pseudo Stage
      ↓
Final 4B logits
```

두 model의 final logits는 CPU에서 저장된다.

42. Final Model Ensemble

Development phase에서 이미 선택된 2B/4B weight를 final model에도 그대로 적용한다.




Validation을 다시 보면서 ensemble weight를 수정하지 않는다.

이를 통해 development decision과 final training을 분리한다.

43. Complete SSAFY-T+ Decision Pipeline

하나의 test sample은 개념적으로 다음 pipeline을 통과한다.



Argmax
↓
Final Answer

44. Multi-Level Ensemble Structure

SSAFY-T+는 하나의 ensemble만 사용하는 것이 아니라 여러 level의 ensemble을 사용한다.

Level 1 — Option View Ensemble

```
abcd  
bcda  
cdab  
dabc
```

Level 2 — Inference Resolution Ensemble

```
Low-resolution first pass  
+  
High-resolution second pass
```

Level 3 — Decision Representation Ensemble

```
Letter scoring  
+  
Semantic candidate scoring
```

Level 4 — Model Capacity Ensemble

```
Qwen3-VL-2B  
+  
Qwen3-VL-4B
```

따라서 최종 prediction은 단일 forward pass의 결과가 아니라 **여러 독립적인 decision view를 결합한 결과**이다.

45. Multi-View Robustness

SSAFY-T+의 ensemble 구조를 다른 관점에서 보면 동일한 문제를 여러 방식으로 다시 표현한다.

```
Same Image  
Same Question  
Same Candidate Semantics
```

그러나 다음 조건은 바뀐다.

```
Choice order  
Image resolution  
Candidate representation  
Model capacity
```

만약 여러 view에서도 동일한 candidate가 높은 score를 얻는다면 해당 answer는 보다 robust한 prediction으로 간주할 수 있다.

46. Training-Time Diversity

Training 단계에서도 다양한 형태의 input variation을 만든다.

```
Random Option Order  
+  
Random Weak Image Augmentation  
+  
Surprise-based Sample Resampling
```

따라서 매 epoch에서 동일한 dataset을 단순히 같은 형태로 반복해서 보는 것이 아니다. 하나의 sample도 epoch마다 다른 choice ordering이나 약간 다른 visual appearance를 가질 수 있다.

47. Inference-Time Diversity

Inference 단계에서는 stochastic sampling을 사용하지 않는다.

대신 deterministic한 view diversity를 사용한다.

```
Permutation Views
+
Resolution Views
+
Semantic Verification Views
+
Model Capacity Views
```

따라서 reproducibility를 유지하면서 ensemble 효과를 얻는다.

48. Computation Allocation Strategy

SSAFY-T+의 연산량은 모든 sample에 동일하게 배정되지 않는다.

다음은 항상 수행된다.

```
Base letter inference
Permutation ensemble
```

다음은 validation에서 실제 효과가 있는 경우에만 사용된다.

```
Semantic scorer
Permutation ensemble
```

그리고 high-resolution second pass는 low-confidence sample에서만 사용된다.

즉 computation은 크게 세 종류로 나뉜다.

```
Mandatory Compute
Conditional Compute
Validation-Selected Compute
```

이는 전체 architecture를 단순한 brute-force ensemble보다 효율적으로 만든다.

49. Model-Specific Hyperparameters

2B와 4B는 같은 architecture를 사용하지만 동일한 hyperparameter를 사용하지 않는다.

Qwen3-VL-2B

Train batch	= 8
Eval batch	= 8
Grad accumulation	= 2
Language LR	= 1e-4
Vision LR	= 1e-5

Qwen3-VL-4B

Train batch	= 4
Eval batch	= 4
Grad accumulation	= 4
Language LR	= 8e-5
Vision LR	= 8e-6

결과적으로 두 model의 effective batch size는 비슷하게 유지하면서 memory usage를 조절한다.

50. Parameter Group Optimization

Language LoRA parameter와 Vision LoRA parameter는 optimizer에서 별도의 parameter group으로 분리된다.

```

AdamW
├── Language LoRA Parameters
│   └── Higher LR
└── Vision LoRA Parameters
    └── Lower LR
  
```

이를 통해 서로 다른 modality representation에 적합한 update scale을 적용할 수 있다.

51. Efficiency Mechanisms

SSAFY-T+는 매우 복잡한 ensemble architecture이지만 여러 efficiency technique을 동시에 사용한다.

4-bit Quantization

Backbone memory를 줄인다.

LoRA

Trainable parameter 수를 제한한다.

Gradient Checkpointing

Activation memory를 줄인다.

Batched Inference

GPU parallelism을 활용한다.

`logits_to_keep=1`

필요한 마지막 generation position의 logits만 유지한다.

Sequential Model Loading

2B와 4B가 동시에 VRAM을 차지하지 않는다.

Conditional High-Resolution Inference

불확실한 sample에만 높은 visual cost를 사용한다.

52. Validation-Calibrated Architecture

SSAFY-T+의 특징은 단순히 많은 technique을 적용하는 것이 아니다.

각 technique 중 상당 부분은 validation performance를 기반으로 선택된다.

Permutation

→ Identity보다 좋은가?

Pseudo Stage

→ Stage1보다 좋은가?

Second Pass Threshold

→ 어떤 threshold가 가장 좋은가?

Semantic Scorer

→ 어느 weight가 좋은가?

2B/4B Ensemble

→ 어느 weight 조합이 좋은가?

즉 architecture 내부에 여러 선택 mechanism이 존재한다.

53. Failure-Mode-Oriented Design

SSAFY-T+의 각 component는 서로 다른 failure mode를 대상으로 한다.

Failure Mode	대응 Mechanism
Answer position bias	Option permutation
Weak visual adaptation	Vision LoRA
Overfitting	Weak augmentation
Single-model error	2B/4B ensemble
Letter-token bias	Semantic candidate scorer
Hard example neglect	Surprise replay
Strong distractor	Margin loss
Low-confidence visual ambiguity	High-res second pass
Limited gold sample usage	Final 100% retraining
Noisy dev labels	Human/teacher filtering

따라서 architecture 복잡성이 단순한 기능 추가가 아니라 오류 유형별 대응 전략의 조합이라는 점이 중요하다.

54. Relationship Between Surprise and Augmentation

Surprise Replay와 image augmentation은 서로 다른 역할을 한다.

Augmentation은

같은 semantic sample
→ 다양한 visual observation

을 제공한다.

Surprise Replay는

현재 어려운 sample

→ 더 많은 observation

을 제공한다.

두 mechanism을 결합하면 high-surprise sample이 replay될 때마다 약간 다른 augmented image를 볼 수 있다.

따라서 hard sample을 단순 암기하는 대신 다양한 appearance를 통해 반복적으로 학습할 가능성이 높아진다.

55. Relationship Between Permutation and Semantic Scoring

Option permutation은 answer-position dependency를 약화한다.

Semantic scorer는 position 자체를 사용하지 않고 candidate text를 직접 검증한다.

따라서 두 mechanism은 서로 보완적이다.

Permutation

→ 위치 bias 감소

Semantic Scorer

→ 위치와 독립적인 의미 검증

둘 모두 `a/b/c/d`가 가진 arbitrary label nature를 보완한다.

56. Relationship Between 2B and 4B Experts

SSAFY-T+에서 2B와 4B는 단순히 동일 model의 작은 버전과 큰 버전으로만 취급하지 않는다.

각각 별도의 expert로 본다.

2B Expert

→ efficiency / simpler representation

4B Expert

→ capacity / complex reasoning

Validation-based weighted ensemble은 어느 expert가 실제 dataset에 더 적합한지를 자동으로 반영한다.

예를 들어 4B가 압도적으로 좋은 경우 validation에서 4B weight가 높아질 수 있다.

반대로 2B와 4B가 서로 보완적인 경우 두 model 모두 의미 있는 weight를 갖게 된다.

57. Final Training Philosophy

SSAFY-T+의 final retraining은 다음 철학을 따른다.


Validation은 모델을 선택하기 위해 존재하고, 최종 모델을 훈련시키지 못하게 하기 위해 존재하는 것은 아니다.


즉 development 단계에서는 holdout이 필요하지만 모든 설정이 결정된 이후에는 가능한 모든 gold supervision을 final model에 활용한다.

이를 통해 작은 dataset 환경에서 labeled sample efficiency를 최대화한다.


58. Overall Training Architecture

SSAFY-T+의 전체 training 구조는 다음과 같다.






59. Overall Final Architecture



60. Final Inference Architecture



61. SSAFY-T vs SSAFY-T+

Component	SSAFY-T	SSAFY-T+
Backbone	Qwen3-VL-2B	Qwen3-VL-2B + 4B
4-bit NF4	O	O
Language LoRA	O	O
Vision LoRA	X	O
Direct 4-choice CE	O	O

Hard-negative margin	O	O
Surprise Replay	O	O
DEV pseudo-label	O	O
Weak image augmentation	X	O
Option permutation training	X	O
Permutation inference	X	O
Semantic scorer	X	O
High-res second pass	O	O
Model ensemble	X	O
Validation-calibrated model weight	X	O
Gold 100% final retraining	X	O
Validation-final phase separation	부분적	명시적

62. Design Philosophy

SSAFY-T+의 설계 철학은 네 가지 원칙으로 요약할 수 있다.

1. Remove arbitrary shortcuts.

선지 letter와 위치에 의존하는 shortcut을 option permutation으로 억제한다.

2. Learn from multiple representations.

Visual feature, letter choice, semantic candidate, model scale이라는 서로 다른 representation을 함께 활용한다.

3. Allocate compute adaptively.

Surprise가 높은 sample을 더 학습하고, confidence가 낮은 sample을 더 자세히 추론한다.

4. Use every reliable supervision signal.

Gold data, human consensus, teacher agreement, augmentation, full-gold retraining을 통해 제한된 dataset의 supervision efficiency를 높인다.

이를 한 문장으로 압축하면 다음과 같다.

SSAFY-T+ learns from multiple views, adapts where uncertainty remains, and combines independent evidence before making the final decision.

63. Limitations

SSAFY-T+는 SSAFY-T보다 강력하지만 몇 가지 명확한 단점도 존재한다.

63.1 Increased Computational Cost

2B와 4B를 모두 학습하고 각각 permutation, semantic scoring, second pass를 수행하므로 computation cost가 크게 증가한다.

63.2 Semantic Scorer Cost

Semantic scorer는 하나의 문제당 네 candidate를 각각 별도로 검증한다.

따라서 일반 letter inference보다 약 4배 많은 prompt evaluation이 필요할 수 있다.

63.3 Validation Overfitting Risk

많은 hyperparameter를 같은 validation set에서 결정한다.

```
Best epoch
Pseudo epoch
Permutation
Second-pass threshold
Semantic weight
2B/4B ensemble weight
```

실험을 과도하게 반복하면 validation-specific optimization이 발생할 가능성이 있다.

63.4 Vision LoRA Target Discovery

Vision LoRA module은 model의 module name pattern을 기반으로 자동 탐색한다.

Transformers 또는 Qwen implementation 구조가 변경되면 target discovery logic도 수정해야 할 수 있다.

63.5 Fixed Permutation Set

Inference에서는 전체 24개 permutation이 아니라 네 개의 cyclic permutation만 사용한다.

이는 computation cost를 줄이기 위한 선택이지만 모든 possible ordering bias를 완전히 제거하는 것은 아니다.

63.6 Simple Semantic Verification

Semantic scorer는 `yes/no` first-token likelihood를 사용한다.

따라서 candidate correctness에 대한 복잡한 reasoning을 전부 활용하는 별도 reward model이나 verifier보다 단순하다.

63.7 No Independent Final Holdout

Gold 100% retraining 이후에는 별도의 untouched labeled holdout이 남지 않는다.

따라서 final retrained model의 실제 generalization accuracy는 external test set 또는 leaderboard에서만 확인할 수 있다.

64. Summary

- *SSAFY-T+*는 SSAFY-T의 surprise-sensitive adaptive learning framework를 확장하여, single-model VQA architecture에서 **multi-model, multi-view, multi-representation VQA system**으로 발전시킨 모델이다.

핵심 구조는 다음과 같다.

```
Qwen3-VL-2B
+
Qwen3-VL-4B
+
4-bit QLoRA
+
Language LoRA
+
Late Vision LoRA
+
Direct 4-Choice CE
+
Hard-Negative Margin
+
Titans-Inspired Surprise Replay
+
Question-Aware Weak Augmentation
+
Random Option Permutation
+
Permutation Inference Ensemble
```

```

+
Human/Teacher Pseudo Labels
+
Confidence-Based High-Resolution Reinspection
+
Semantic Candidate Verification
+
Validation-Calibrated Score Fusion
+
Validation-Calibrated 2B/4B Ensemble
+
Gold 100% Final Retraining

```

SSAFY-T+에서 하나의 prediction은 더 이상 단일 model이 한 번 수행한 inference 결과가 아니다.

동일한 문제를 서로 다른 option ordering, image resolution, semantic representation, model capacity에서 평가한 후 그 evidence를 통합한다.

Training에서도 동일한 원칙을 따른다. 약한 image augmentation과 random option permutation을 통해 input diversity를 높이고, surprise replay를 통해 모델이 지속적으로 어려워하는 sample에 추가 학습 자원을 배정한다.

Development phase에서는 90% gold data로 모델을 학습하고 10% validation을 이용해 architecture 내부의 여러 decision parameter를 calibration한다. 모든 설정이 결정된 후에는 validation의 역할을 종료하고 pretrained backbone을 다시 load하여 gold data 100%로 final model을 재학습한다.

따라서 SSAFY-T+의 핵심은 다음 세 단계로 요약할 수 있다.

```

Diversify the Evidence
↓
Calibrate the Decision
↓
Retrain with All Reliable Data

```

최종적으로 SSAFY-T+는 한 모델의 확신에 의존하는 대신 여러 독립적인 관점의 증거를 결합하고, 불확실성이 존재하는 부분에만 추가 학습과 추론 자원을 배정하는 **adaptive ensemble VQA architecture**로 정의할 수 있다.

SSAFY-T+ does not rely on a single answer path; it gathers multiple forms of evidence, calibrates their reliability, and then commits to the final choice.