

SSAFY-T

SSAFY-T: Surprise-Sensitive Adaptive Framework for Your Answers with Titans

1. Overview

SSAFY-T (Surprise-Sensitive Adaptive Framework for Your Answers with Titans)는 이미지 기반 4지선다 Visual Question Answering(VQA) 문제를 위해 설계한 parameter-efficient multimodal learning framework이다.

SSAFY-T는 기존 SSAFY가 사용하던 QLoRA 기반 Vision-Language Model 구조를 확장하여, 단순한 정답 token 생성 문제를 **직접적인 4-class multiple-choice optimization** 문제로 재정의한다. 또한 모델이 어려워하는 샘플에 학습 자원을 선택적으로 집중시키기 위해 Titans의 surprise-sensitive memory 개념에서 영감을 받은 **Surprise Replay**를 도입한다.

SSAFY-T의 주요 설계 요소는 다음과 같다.

1. Qwen3-VL-2B-Instruct 기반 multimodal backbone
2. 4-bit NF4 QLoRA
3. Language-model projection에 한정된 LoRA adaptation
4. 직접적인 4-choice Cross Entropy objective
5. Hard-negative margin loss
6. Titans-inspired Surprise Replay
7. Human consensus와 teacher prediction을 이용한 pseudo-label learning
8. Confidence margin 기반 adaptive second-pass inference
9. 저신뢰 문제에 대한 고해상도 재추론
10. Validation 기반 best checkpoint 및 second-pass threshold 선택
11. Batched inference와 `logits_to_keep=1` 을 통한 계산 효율화

SSAFY-T의 핵심 철학은 다음과 같이 정리할 수 있다.

| **"Spend computation where the model is surprised."**

즉 이미 쉽게 해결하는 문제에 동일한 학습 및 추론 자원을 반복적으로 사용하는 대신, 높은 loss나 낮은 confidence를 보이는 문제에 추가적인 계산 자원을 배정한다.

2. From SSAFY to SSAFY-T

기본 SSAFY의 학습 objective는 causal language modeling에 기반한다.

예를 들어 정답이 **c** 라면 전체 vocabulary에 대해 **c** token의 probability를 증가시키는 방식이다.

$$L_{\text{SSAFY}} = -\log P(c \mid I, Q, O)$$


반면 실제 competition의 평가 문제는 자연어 generation이 아니라 다음 문제이다.

$$\hat{y} = \arg \max_{k \in a, b, c, d} s_k$$

즉 네 개의 선택지 중 어느 것이 가장 높은 score를 갖지만 중요하다.

SSAFY-T는 이 training-inference mismatch를 줄이기 위해 학습 과정 자체를 네 개의 choice logits에 대한 직접적인 classification 문제로 변경한다.

개념적인 발전 과정은 다음과 같다.



따라서 SSAFY-T는 SSAFY의 backbone을 단순히 확대하는 모델이 아니라, **학습 objective와 계산 자원 배분 방식을 VQA multiple-choice task에 맞게 재설계한 확장 architecture**이다.

3. Problem Formulation

각 데이터 샘플을 다음과 같이 정의한다.

$$x_i = (I_i, Q_i, O_i)$$

여기서

- (I_i) : 입력 이미지
- (Q_i) : 이미지에 대한 자연어 질문
- $(O_i = \{o_a, o_b, o_c, o_d\})$: 네 개의 선택지

이며, 학습 데이터에는 추가적으로 gold answer가 존재한다.

$$y_i \in a, b, c, d$$

모델은 image, question, candidate answers를 입력으로 받아 각 선택지에 대한 score를 계산한다.

$$\mathbf{z}_i = [z_i, a, z_i, b, z_i, c, z_i, d]$$

최종 prediction은 다음과 같다.

$$\hat{y}_i = \arg \max_{k \in a, b, c, d} z_{i, k}$$

SSAFY-T에서는 이 네 개의 score를 단순 inference에만 사용하는 것이 아니라 **training objective 자체에 직접 사용한다.**

4. Dataset Organization

SSAFY-T는 `train`, `dev`, `test` 세 종류의 데이터를 서로 다른 역할로 활용한다.

4.1 Gold Training Data

`train.csv` 는 다음 구조를 갖는다.

Field	Description
<code>id</code>	샘플 식별자
<code>path</code>	이미지 파일 경로

Field	Description
<code>question</code>	이미지 기반 질문
<code>a</code>	선택지 A
<code>b</code>	선택지 B
<code>c</code>	선택지 C
<code>d</code>	선택지 D
<code>answer</code>	gold label

Gold dataset은 정답 class에 대해 stratification을 적용하여 90:10으로 분리한다.

```

Gold Dataset
├── 90% → Gold Training Set
└── 10% → Fixed Validation Set

```

Validation set은 Stage 1 및 Stage 2 학습 데이터에서 제외하며, checkpoint selection과 adaptive inference threshold calibration에 사용한다.

4.2 Development Data

`dev.csv`에는 단일 gold label 대신 다섯 명의 인간 응답이 존재한다.

```

answer1
answer2
answer3
answer4
answer5

```

SSAFY-T에서는 dev data 전체를 곧바로 supervised dataset으로 사용하지 않는다.

대신 다음 두 신호를 결합한다.

- Human consensus
- Stage 1 teacher model prediction


두 신호가 충분히 강하게 일치하는 sample만 pseudo-labeled training data로 선택한다.

이 구조는 dev annotation에 포함될 수 있는 noise가 그대로 model에 주입되는 것을 방지하기 위한 confidence filtering mechanism이다.

5. Base Multimodal Architecture

SSAFY-T의 backbone은 **Qwen3-VL-2B-Instruct**이다.

전체 입력 구조는 다음과 같다.



Vision module은 입력 이미지를 visual representation으로 변환하며, language model은 visual token과 question/choice token을 공동으로 처리한다.

SSAFY-T는 별도의 CNN classifier를 추가하지 않는다.

그 이유는 **a**, **b**, **c**, **d**가 고정된 semantic class가 아니기 때문이다.

예를 들어 다음과 같이 동일한 **c**가 문제마다 다른 의미를 가질 수 있다.

Question A
(c) 플라스틱

Question B
(c) 유리

Question C
(c) 종이

따라서 모델은 단순한 이미지 classification이 아니라

Visual Understanding
+
Question Understanding
+
Candidate Understanding
+
Cross-modal Alignment

을 동시에 수행해야 한다.

6. 4-bit NF4 QLoRA

SSAFY-T는 backbone model을 4-bit NF4로 quantize한다.

주요 설정은 다음과 같다.

```
load_in_4bit          = True
bnb_4bit_use_double_quant = True
bnb_4bit_quant_type    = NF4
```

원본 parameter를 W 라고 하면 quantized backbone은 개념적으로 다음과 같이 표현할 수 있다.

$$\tilde{W} = Q_{\text{NF4}}(W)$$

Backbone weight는 직접 update하지 않고 LoRA parameter만 학습한다.

LoRA는 기존 linear transformation에 low-rank residual을 추가한다.

$$h = \tilde{W}x + \Delta Wx$$

여기서

$$\Delta W = BA$$

이며

$$A \in \mathbb{R}^{r \times d}, B \in \mathbb{R}^{d' \times r}$$

이다.

SSAFY-T의 LoRA 설정은 다음과 같다.

```
Rank r      = 8
LoRA alpha  = 16
LoRA dropout = 0.05
Bias        = none
```

따라서 scaling coefficient는 일반적으로 $\alpha/r = 16/8 = 2$ 로 볼 수 있다.

7. Language-Only LoRA Adaptation

현재 SSAFY-T 구현에서는 vision module을 LoRA 대상에서 명시적으로 제외한다.

```
if "vision" in module_name
or "visual" in module_name:
    skip
```

LoRA는 language model 내부의 다음 projection에 적용된다.


Self-Attention

```
q_proj
k_proj
v_proj
o_proj
```

Feed-Forward Network

```
gate_proj
up_proj
down_proj
```

따라서 현재 SSAFY-T의 parameter adaptation 구조는 다음과 같다.



이 방식은 작은 domain dataset에서 전체 VLM을 fine-tuning할 때 발생할 수 있는 catastrophic forgetting과 GPU memory consumption을 줄이는 역할을 한다.

8. Prompt Representation

각 문제는 multimodal chat template 형태로 변환된다.

System instruction은 모델에게 다음 제약을 부여한다.

- 이미지를 면밀하게 분석한다.
- 문제와 네 개의 선택지를 해석한다.
- 출력은 a, b, c, d 중 하나여야 한다.
- 설명은 출력하지 않는다.

User prompt는 다음과 같은 형태이다.

```
<IMAGE>

<Question>

(a) Option A
(b) Option B
(c) Option C
(d) Option D

정답을 a, b, c, d 중 하나의 소문자 한 글자로만 출력하세요.
```

중요하게도 SSAFY-T의 training input에는 gold answer를 assistant message로 추가하지 않는다.

즉 모델은 다음 generation position에서 어떤 answer token이 나와야 하는지를 직접 평가한다.

9. Dynamic Choice-Token Discovery

SSAFY-T는 a, b, c, d의 token ID를 하드코딩하지 않는다.

Qwen의 실제 chat template에 dummy multiple-choice example을 넣고 각 answer를 assistant output으로 추가한다.

```
Prompt + assistant "a"
Prompt + assistant "b"
Prompt + assistant "c"
Prompt + assistant "d"
```

Prompt token sequence 이후 처음 등장하는 token을 해당 choice의 token ID로 기록한다.

이를 각각 t_a, t_b, t_c, t_d 라고 하자.

SSAFY-T는 네 token이 서로 다른 token ID로 표현되는지도 검증한다.

이 과정은 tokenizer 구현이나 chat template에 따른 tokenization 차이에 대한 robustness를 확보한다.

10. Direct Four-Choice Objective

SSAFY와 SSAFY-T의 가장 중요한 차이 중 하나이다.

모델의 next-token vocabulary logits를

$$\mathbf{v}_i \in \mathbb{R}^{|V|}$$

라고 하자.

SSAFY-T는 vocabulary 전체를 training classification space로 사용하지 않고 네 choice token에 해당하는 logit만 선택한다.

$$\mathbf{z}_i = [v_i, t_a, v_{i,t_b}, v_{i,t_c}, v_{i,t_d}]$$

따라서 모델의 training output은 직접적으로

$$\mathbf{z}_i \in \mathbb{R}^4$$

가 된다.

Gold label을 integer index $y_i \in 0, 1, 2, 3$ 로 변환하면 multiple-choice Cross Entropy는 다음과 같다.

$$L_{MC,i} = -\log \frac{\exp(z_{i,y_i})}{\sum_{k=1}^4 \exp(z_{i,k})}$$

Batch-level MC loss는 sample weight w_i 를 고려하여 다음과 같이 정의된다.

$$L_{MC} = \frac{1}{B} \sum_{i=1}^B w_i L_{MC,i}$$

Gold training sample의 기본 weight는 1이다.

이 구조의 가장 중요한 장점은 **training objective**와 실제 **competition decision rule**이 직접적으로 일치한다는 것이다.

```
Training:
a/b/c/d 중 정답 score 증가

Inference:
a/b/c/d 중 최대 score 선택
```

11. Hard-Negative Margin Learning

Cross Entropy는 정답 class의 상대적 probability를 증가시키지만, SSAFY-T는 여기에 추가적으로 가장 위험한 오답과 정답 사이의 **score separation**을 명시적으로 학습한다.

각 sample에서 correct logit을 다음과 같이 정의한다.

$$z_i^+ = z_{i,y_i}$$

나머지 세 오답 중 가장 높은 score를 갖는 hard negative는

$$z_i^- = \max_{k \neq y_i} z_{i,k}$$

이다.

SSAFY-T의 margin loss는 다음 hinge form을 사용한다.

$$L_{\text{margin},i} = \max(0, m - z_i^+ + z_i^-)$$

현재 margin은 1.0 으로 설정되어 있다.

즉 단순히 correct class가 top-1이 되는 것만으로 충분하지 않고, 가장 경쟁력 있는 wrong choice보다 최소 1.0 이상의 logit margin을 형성하도록 유도한다.

Sample weight를 적용한 batch margin loss는 다음과 같다.

$$L_{\text{margin}} = \frac{1}{B} \sum_{i=1}^B w_i L_{\text{margin},i}$$

최종 training objective는 다음과 같다.

$$L = L_{\text{MC}} + \lambda L_{\text{margin}}$$

현재 구현에서 램다값은 0.2 이다.

12. Why Hard-Negative Optimization Matters

예를 들어 다음 logits를 가정한다.

```
Gold = c
a = 4.8
b = 0.1
c = 4.9
d = -0.5
```

일반 accuracy 기준에서는 이미 올바른 prediction이다.

그러나 $z_c - z_a = 0.1$ 로 decision boundary가 매우 불안정하다.

작은 이미지 noise나 prompt variation만으로도 prediction이 **a**로 바뀔 수 있다.

Margin objective는 이러한 near-boundary sample에 추가 loss를 부여한다.

$$L_{\text{margin}} = \max(0, 1.0 - 4.9 + 4.8) = 0.9$$

따라서 SSAFY-T는 단순한 정답률뿐 아니라 **correct answer와 hardest competing answer 사이의 separation**을 증가시키도록 학습된다.

13. Titans-Inspired Surprise Replay

SSAFY-T의 이름에서 **T**는 Titans의 surprise-driven memory 개념에서 영감을 받은 학습 전략을 의미한다.

다만 SSAFY-T는 Titans의 neural long-term memory architecture 자체를 구현하지 않는다.

대신 Titans의 핵심 아이디어인

▮ 예상과 크게 어긋나는 정보, 즉 높은 surprise를 보이는 정보를 더 강하게 기억한다.

라는 원리를 **sample-level prioritized replay** 형태로 변형한다.

14. Definition of Surprise

SSAFY-T에서 sample i 의 instantaneous surprise는 해당 sample의 multiple-choice Cross Entropy로 정의한다.

$$\tilde{S}_i^{(t)} = L_{\text{MC},i}^{(t)}$$

높은 CE loss는 모델이 해당 문제를 아직 제대로 설명하지 못한다는 뜻이므로 높은 surprise로 해석한다.

Surprise score는 한 번의 loss에 의해 급격히 변하지 않도록 Exponential Moving Average를 사용한다.

$$S_i^{(t)} = \beta S_i^{(t-1)} + (1 - \beta) \tilde{S}_i^{(t)}$$

현재 구현에서의 베타값은 0.8이다.

15. Surprise as Adaptive Memory

이 EMA 구조는 단기적으로 loss가 한 번 높아진 sample보다 **지속적으로 어려운 sample**에 높은 priority를 부여한다.

예를 들어 어떤 sample의 loss가 다음과 같다고 하자.

```
Epoch 1 : 2.3  
Epoch 2 : 1.9  
Epoch 3 : 1.4  
Epoch 4 : 0.2  
Epoch 5 : 0.1
```

초기에는 높은 surprise score를 갖기 때문에 replay될 가능성이 높다.

하지만 모델이 문제를 학습하고 CE가 감소하면 EMA surprise 역시 서서히 감소한다.

즉 SSAFY-T의 memory는 다음 행동을 갖는다.

```
모델이 계속 어려워함  
↓  
High Surprise  
↓  
Replay Probability ↑  
↓  
추가 학습  
↓
```

문제를 학습함
↓
Loss ↓
↓
Surprise EMA ↓
↓
Replay Priority ↓

이는 hard-example memory가 고정된 것이 아니라 **모델의 현재 학습 상태에 따라 동적으로 변화하는 adaptive memory**라는 의미이다.

16. Surprise-Weighted Replay Sampling

각 epoch에서 전체 original training sample은 한 번씩 기본적으로 포함된다.

추가적으로 전체 dataset 크기의 일정 비율만큼 replay sample을 생성한다.

현재 설정은 $r_{\text{replay}} = 0.25$ 이다.

Dataset size를 N 이라고 하면 추가 replay sample 수는

$$N_{\text{replay}} = \lfloor 0.25N \rfloor$$

이다.

Sample i 가 replay 대상으로 선택될 probability는 surprise score에 비례한다.

$$P(i) = \frac{S_i}{\sum_j S_j}$$

따라서 epoch별 effective sample count는 대략

$$N_{\text{epoch}} \approx 1.25N$$

이 된다.

하지만 추가된 25%가 uniform random sample이 아니라 **현재 모델이 어려워하는 문제들에 편향된 sample**이라는 점이 핵심이다.

17. Difference from Standard Hard Example Mining

일반적인 hard-example mining은 특정 시점에서 loss가 가장 큰 sample을 선택하는 경우가 많다.

SSAFY-T는 다음 두 가지 차이를 갖는다.

첫째, binary hard/easy classification 대신 continuous surprise value를 사용한다.

둘째, instantaneous loss가 아닌 EMA memory를 사용한다.

따라서 갑작스러운 stochastic loss spike에 덜 민감하며, 여러 epoch 동안 지속적으로 어려운 sample에 안정적으로 자원을 집중할 수 있다.

이를 다음과 같이 볼 수 있다.

```
Standard Shuffle
  → 모든 sample 동일 priority

Hard Mining
  → 현재 loss가 큰 sample 선택

SSAFY-T Surprise Replay
  → 최근 학습 history를 반영한
    persistent difficulty 기반 sampling
```

18. Stage 1 Training

Stage 1은 gold training data만 사용한다.

현재 기본 설정은 다음과 같다.

```
Epochs           = 8
Batch size        = 8
Gradient Accumulation = 2
Learning Rate     = 1e-4
Weight Decay      = 0.01
Warmup Ratio      = 0.03
Replay Ratio      = 0.25
```

일반적인 effective batch size는

$$B_{\text{eff}} = 8 \times 2 = 16$$

이다.

Surprise replay에 의해 하나의 epoch에서 처리하는 sample 수는 원본 dataset보다 약 25% 증가한다.

19. Gradient Accumulation and Optimization

SSAFY-T는 AdamW optimizer를 사용한다.

Learning rate는 $\eta = 10^{-4}$ 이며 weight decay는 $\lambda_{wd} = 0.01$ 이다.

Gradient accumulation을 통해 두 mini-batch의 gradient를 합산한 후 optimizer update를 수행한다.

마지막 accumulation group의 batch 수가 설정된 `GRAD_ACCUM` 보다 적을 수 있으므로, SSAFY-T는 실제 group size에 맞추어 loss scaling divisor를 동적으로 조정한다.

Gradient norm은 $\|g\|_2 \leq 1.0$ 으로 clipping한다.

이는 hard-negative sample이나 surprise replay sample에서 큰 gradient가 발생했을 때 optimizer instability를 완화한다.

20. Learning-Rate Scheduling

전체 optimizer step 수를 T 라고 하면 warmup step 수는 $T_w = 0.03T$ 로 설정한다.

Warmup 이후 learning rate는 training 종료까지 linearly decay한다.

이는 quantized pretrained model 위에 새롭게 초기화된 LoRA adapter를 학습할 때 초기 update가 지나치게 크게 발생하는 것을 방지한다.

21. Best Checkpoint Selection

SSAFY-T는 총 8 epoch를 학습하며 기본적으로 2 epoch마다 validation한다.

```
Epoch 2 → Validation  
Epoch 4 → Validation  
Epoch 6 → Validation  
Epoch 8 → Validation
```

Validation metric은 Accuracy이다.

$$Accuracy = \frac{1}{N} \sum_{i=1}^N \mathbf{1}(\hat{y}_i = y_i)$$

현재 best validation accuracy보다 높은 checkpoint가 발견되면 LoRA adapter parameter를 CPU memory에 저장한다.

Stage 1 종료 후 마지막 epoch model이 아니라 **best validation checkpoint**를 복원한다.

22. Multi-Annotator Pseudo-Label Learning

Stage 2는 gold training data에 dev data의 일부를 추가하는 semi-supervised learning 단계이다.

Dev sample에는 다섯 개의 인간 응답이 존재한다.

$$A_i = a_i^{(1)}, a_i^{(2)}, a_i^{(3)}, a_i^{(4)}, a_i^{(5)}$$

각 선택지의 vote count를

$$c_i(k) = \sum_{j=1}^5 \mathbf{1}(a_i^{(j)} = k)$$

라고 정의한다.

Human majority label은

$$h_i = \arg \max_k c_i(k)$$

이며 human confidence는

$$C_i^H = \frac{\max_k c_i(k)}{|A_i|}$$

이다.

SSAFY-T는

$$C_i^H \geq 0.8$$

인 sample만 후보로 사용한다.

다섯 명의 응답이 모두 유효하다면 이는 최소 4/5 이상의 agreement를 의미한다.

23. Teacher Agreement Filtering

Human majority만으로 pseudo-label을 결정하지 않는다.

Stage 1 best model을 teacher로 사용하여 dev data를 inference한다.

Teacher prediction을 t_i 라고 하고, teacher의 top-1 score와 top-2 score 차이를

$$M_i = z_i^{(1)} - z_i^{(2)}$$

라고 정의한다.

Pseudo-label로 채택되기 위한 조건은 다음과 같다.

$$C_i^H \geq 0.8, t_i = h_i, M_i \geq 1.0$$

즉

```
Human consensus >= 4/5
  AND
Teacher prediction = Human majority
  AND
Teacher margin >= 1.0
  ↓
Accept pseudo-label
```

이다.

이러한 multi-signal filtering은 인간 annotation noise와 teacher error가 동시에 pseudo-label

dataset에 포함될 확률을 감소시키기 위한 보수적인 전략이다.

24. Confidence-Weighted Pseudo Labels

Pseudo-label sample은 gold sample과 동일한 신뢰도로 취급하지 않는다.

Gold sample은 $w_i = 1.0$ 을 사용한다.

Pseudo sample의 weight는 $w_i = \alpha_p C_i^H$ 로 정의하며 현재 $\alpha_p = 0.5$ 이다.

따라서 5/5 agreement sample의 weight는 $w_i = 0.5$ 이고 4/5 agreement sample의 weight는

$w_i = 0.5 \times 0.8 = 0.4$ 이다.

즉 pseudo-labeled data가 gold supervision보다 강한 gradient를 발생시키지 못하도록 제한한다.

25. Stage 2 Fine-Tuning

Stage 2 training dataset은 다음과 같다.

$$D_{\text{Stage2}} = D_{\text{gold}} \cup D_{\text{pseudo}}$$

Stage 2에서는 Stage 1보다 작은 learning rate를 사용한다.


$$\eta_{\text{Stage1}} = 10^{-4}, \eta_{\text{Stage2}} = 2 \times 10^{-5}$$

즉 pseudo-label에 의해 이미 학습된 representation이 급격하게 이동하는 것을 방지하기 위해 Stage 2 learning rate를 Stage 1의 20% 수준으로 감소시킨다.

Stage 2는 최대 2 epoch 수행하며 매 epoch validation accuracy를 평가한다.

Stage 2가 Stage 1 best accuracy를 개선한 경우에만 해당 checkpoint를 채택한다.

그렇지 않으면 Stage 1 checkpoint를 복원한다.



따라서 pseudo-label learning은 기본적으로 **non-destructive optional refinement stage**로 동작한다.

26. Batched Multiple-Choice Inference

기본 SSAFY는 sample 단위 inference를 수행할 수 있지만 SSAFY-T는 batch inference를 사용한다.

또한 tokenizer padding을

```
padding_side = left
```

로 설정한다.

이를 통해 서로 다른 길이의 prompt를 batch로 묶더라도 모든 sample에서 마지막 tensor position이 실제 assistant generation position이 된다.

따라서 batch 전체에 대해

```
outputs.logits[:, -1, :]
```

을 직접 사용할 수 있다.

27. logits_to_keep=1

VLM의 vocabulary projection은 일반적으로 모든 sequence position에 대해 vocabulary-sized logit vector를 생성할 수 있다.

Sequence length를 L , vocabulary size를 $|V|$ 라고 하면 일반적인 output tensor는 개념적으로

$$Z \in \mathbb{R}^{B \times L \times |V|}$$

형태가 된다.

그러나 SSAFY-T에서 필요한 것은 마지막 generation position뿐이다.

따라서

```
logits_to_keep = 1
```

을 사용하여 마지막 위치의 vocabulary projection만 유지한다.

필요한 output은

$$Z_{\text{last}} \in \mathbb{R}^{B \times |V|}$$

가 된다.

그중 다시 네 choice token만 선택하므로 실제 decision에 사용하는 score는

$$Z_{\text{choice}} \in \mathbb{R}^{B \times 4}$$

이다.

이는 특히 batched inference에서 memory consumption을 줄이는 역할을 한다.

28. Confidence Estimation

SSAFY-T의 adaptive inference는 top-1/top-2 margin을 uncertainty signal로 사용한다.

4-choice logits의 descending order를 $z_{(1)} \geq z_{(2)} \geq z_{(3)} \geq z_{(4)}$ 라고 할 때 confidence margin은 $M = z_{(1)} - z_{(2)}$ 로 정의한다.

Margin이 크면 모델이 가장 좋은 choice와 두 번째 choice를 명확히 구분한다는 의미이다.

반대로 margin이 작으면 두 candidate 사이에서 decision boundary가 불안정하다고 해석한다.

29. Adaptive Second-Pass Inference

모든 test sample을 고해상도로 처리하면 계산량이 크게 증가한다.

SSAFY-T는 first-pass confidence에 따라 추가 inference 여부를 결정한다.

Pass 1

일반적인 pixel budget을 사용한다.

```
LOW_MIN_PIXELS = 224 × 224
LOW_MAX_PIXELS = 384 × 384
```

먼저 네 candidate score를 계산한다.

```
Image
↓
Low-resolution processor
↓
Qwen3-VL
↓
[a, b, c, d]
```

↓
Confidence margin

Margin이 충분히 높으면 해당 prediction을 그대로 사용한다.

Margin이 낮으면 second pass 대상으로 routing한다.

30. Validation-Based Threshold Calibration

Second-pass를 언제 실행할지 임의로 결정하지 않는다.

다음 threshold candidate들을 validation set에서 탐색한다.

```
0.00  
0.10  
0.25  
0.50  
0.75  
1.00  
1.50  
2.00
```

Threshold를 τ 라고 하면 second pass 조건은 다음과 같다.

$$M_i \leq \tau$$

각 τ 에 대해 validation accuracy를 측정하고 가장 높은 accuracy를 제공하는 값을 선택한다.

$$\tau^* = \arg \max_{\tau} Accuracy_{val}(\tau)$$

이후 test inference에서는 고정된 τ^* 를 사용한다.

31. High-Resolution Re-Inspection

Second pass 대상 sample은 더 높은 image pixel budget으로 다시 처리한다.

```
HIGH_MIN_PIXELS = 256 × 28 × 28  
HIGH_MAX_PIXELS = 768 × 28 × 28
```

추가적으로 first pass에서 가장 score가 높은 두 candidate를 prompt에 명시한다.

예:

```
The first evaluation was uncertain.  
Pay particular attention to options a and c.  
Inspect the visual evidence again and  
choose the better-supported answer.
```

즉 second pass는 단순히 같은 연산을 반복하지 않고 다음 두 가지 정보를 추가한다.

```
More Visual Detail  
+  
Focused Candidate Comparison
```

이를 통해 추가 computation이 실제 decision refinement에 사용되도록 한다.

32. Stable First/Second-Pass Fusion

Second-pass prediction이 first-pass result를 완전히 덮어쓰지 않는다.

First-pass log-probability를 $\ell_i^{(1)}$, second-pass log-probability를 $\ell_i^{(2)}$ 라고 하면 final score는 다음과 같이 계산한다.

$$\ell_i^{\text{final}} = (1 - \gamma)\ell_i^{(1)} + \gamma\ell_i^{(2)}$$

현재 감마값은 0.7이다.


고해상도 second-pass에 더 높은 weight를 주되 first-pass evidence도 30% 유지한다.

이는 iterative refinement 과정에서 하나의 불안정한 second prediction이 기존 decision을 과도하게 뒤집는 것을 완화한다.

33. Adaptive Compute Allocation

SSAFY-T의 inference architecture를 computational routing 관점에서 보면 다음과 같다.

```
Input  
|
```



따라서 쉬운 문제에는 한 번의 forward pass만 사용하고, 어려운 문제에만 additional computation을 배정한다.

이를 평균 inference cost 관점에서 표현할 수 있다.

Second pass 비율을 p 라고 하고 first/second pass cost를 각각 C_1 , C_2 라고 하면 전체 평균 cost는

$$E[C] = C_1 + pC_2$$

이다.

모든 sample에 second pass를 수행하는 경우

$$C_{\text{all}} = C_1 + C_2$$

인 것과 비교하면, $p < 1$ 인 한 평균 계산량을 절감할 수 있다.

34. Unified Surprise-Sensitive View

SSAFY-T의 training과 inference는 서로 다른 mechanism처럼 보이지만 동일한 철학을 따른다.

Training

높은 loss를 보이는 sample은 높은 surprise를 갖는다.

$$L_i \uparrow \Rightarrow S_i \uparrow \Rightarrow P_{\text{replay}}(i) \uparrow$$

Inference

낮은 margin을 보이는 sample은 높은 uncertainty를 갖는다.

$$M_i \downarrow \Rightarrow U_i \uparrow \Rightarrow \text{Second Pass}$$

즉 두 과정 모두 모델의 현재 certainty를 기반으로 computational budget을 재분배한다.

```

TRAINING
High Surprise
  ↓
Replay More

INFERENCE
High Uncertainty
  ↓
Reason More

```

이 점이 SSAFY-T의 architecture를 하나의 일관된 adaptive framework로 묶는 핵심이다.

35. Training-Time Adaptation vs Test-Time Adaptation

SSAFY-T는 두 종류의 adaptive behavior를 가진다.

35.1 Training-Time Adaptation

Surprise score가 높은 sample에 sampling probability를 더 많이 부여한다.

따라서 training budget은 모델이 현재 취약한 영역으로 이동한다.


35.2 Test-Time Adaptation

Confidence margin이 낮은 sample에 더 높은 image resolution과 candidate-focused re-evaluation을 할당한다.

따라서 inference budget은 모델이 현재 확신하지 못하는 문제로 이동한다.


이를 종합하면 SSAFY-T는 다음 형태의 closed-loop system으로 해석할 수 있다.

Model State




36. SSAFY-T Overall Training Architecture

전체 Stage 1 training pipeline은 다음과 같다.




37. SSAFY-T Stage 2 Architecture


Pseudo-label refinement stage는 다음과 같다.



38. SSAFY-T Inference Architecture

최종 inference pipeline은 다음과 같다.





39. Computational Efficiency

SSAFY-T는 추가적인 adaptive mechanism을 도입하지만 동시에 여러 efficiency optimization을 사용한다.

39.1 4-bit Backbone

대부분의 pretrained parameter를 NF4로 유지한다.

39.2 LoRA-Only Updates

전체 backbone을 update하지 않는다.

39.3 Gradient Checkpointing

Activation memory를 줄이는 대신 일부 forward computation을 backward에서 재실행한다.

39.4 Batched Inference

한 sample씩 처리하지 않고 여러 image-question pair를 동시에 inference한다.

39.5 `logits_to_keep=1`

전체 sequence position의 vocabulary projection을 계산할 필요를 줄인다.

39.6 Conditional Second Pass

모든 sample이 아니라 uncertainty threshold를 통과한 sample에만 고비용 inference를 수행한다.

따라서 SSAFY-T는 단순히 연산량을 늘리는 architecture라기보다 **동일한 계산 자원을 어려운 sample에 더 선택적으로 배분하는 architecture**를 지향한다.

40. Model Confidence and Diagnostics

SSAFY-T는 최종 prediction 외에도 다음 정보를 저장한다.

```
id
pred
margin_pass1
used_second_pass
score_a
score_b
score_c
score_d
```

이를 통해 다음 분석이 가능하다.

Prediction Distribution

특정 answer token으로 모델 output이 편향되는지 확인할 수 있다.

Confidence Calibration

Pass-1 margin과 실제 정답률 사이의 관계를 분석할 수 있다.

Adaptive Routing Effect

Second pass가 적용된 sample과 그렇지 않은 sample을 구분하여 추가 inference의 실제 효과를 측정할 수 있다.

Error Analysis

어떤 두 choice 사이에서 모델이 반복적으로 혼동하는지 분석할 수 있다.

41. SSAFY vs SSAFY-T

두 architecture의 핵심 차이는 다음과 같다.

Component	SSAFY	SSAFY-T
Backbone	Qwen-VL 계열	Qwen3-VL-2B-Instruct
Quantization	4-bit NF4	4-bit NF4
Fine-tuning	Language LoRA	Language LoRA
Training target	Assistant answer token	Direct 4-choice logits
Main loss	Causal LM CE	4-choice CE
Negative optimization	없음	Hard-negative margin
Hard sample handling	Uniform shuffle	Surprise replay
DEV usage	사용하지 않음	Filtered pseudo-label
Pseudo confidence	없음	Human + teacher
Validation	Best checkpoint	Best Stage1/Stage2 + threshold
Inference	Single pass	Adaptive 1/2 pass
Resolution	Fixed	Confidence-dependent
Test-time routing	없음	Margin-based
Logit fusion	없음	Pass1/Pass2 weighted fusion

SSAFY의 핵심이

Generate less, compare more

라면 SSAFY-T는 이를 다음과 같이 확장한다.

Compare directly, remember surprise, and compute adaptively.

42. Ablation Interpretation

SSAFY-T는 여러 mechanism의 조합으로 이루어져 있으므로 각 component는 서로 다른 failure mode를 대상으로 한다.

Direct 4-Choice CE

Training-inference objective mismatch를 감소시킨다.

Margin Loss

Correct answer와 가장 강한 distractor 사이의 decision margin을 확대한다.

Surprise Replay

반복적으로 틀리는 difficult sample에 training budget을 집중한다.

Pseudo-Label Stage

Human consensus가 높은 dev sample을 이용하여 effective training data를 확장한다.

Teacher Filtering

Noisy pseudo-label 유입을 억제한다.

Confidence-Weighted Pseudo Loss

Pseudo supervision이 gold supervision을 압도하는 것을 방지한다.

High-Resolution Second Pass

시각적 세부정보가 부족해 불확실했던 sample을 보완한다.

Top-2 Focus Prompt

모델이 실제로 혼동했던 candidate pair에 reasoning을 집중한다.

Score Fusion

Second-pass instability를 완화한다.

따라서 SSAFY-T의 각 component는 동일한 최적화 기법을 중복 적용하는 것이 아니라 서로 다른 오류 원인을 겨냥한다.

43. Limitations

현재 SSAFY-T 구현에는 몇 가지 제한이 존재한다.

43.1 Frozen Vision Encoder

현재 LoRA는 language module에만 적용된다.

따라서 recycling-specific appearance와 pretrained vision representation 사이의 domain gap을 vision backbone 자체에서 직접 줄이지 않는다.

43.2 Position Representation

모델의 최종 decision space는 여전히 `a/b/c/d` token이다.

따라서 candidate 위치와 관련된 prior를 완전히 제거하지는 못한다.

43.3 Surprise Is Loss-Based

현재 surprise는 sample의 CE loss만으로 정의한다.

하지만 높은 loss의 원인은 다양할 수 있다.

실제로 어려운 이미지
annotation ambiguity
poor image quality
outlier
잘못된 pseudo label

따라서 모든 high-loss sample이 반드시 유용한 hard example이라고 보장할 수는 없다.

43.4 Pseudo-Label Confirmation Bias

Teacher와 human majority가 일치하는 sample만 선택하여 noise를 줄이지만, teacher의 systematic bias와 human consensus의 systematic error가 일치할 가능성은 남아 있다.

43.5 Validation Reuse

같은 validation set이

- Stage 1 checkpoint selection
- Stage 2 adoption
- second-pass threshold calibration

에 반복적으로 사용된다.

실험을 지나치게 많이 반복하면 validation overfitting이 발생할 수 있다.

43.6 Heuristic Second-Pass Routing

Confidence margin은 단순하고 효율적인 uncertainty measure이지만 완벽하게 calibrated probability를 의미하지 않는다.

높은 margin으로 틀리는 confident error는 second pass 대상으로 선택되지 않는다.

44. Design Philosophy

SSAFY-T의 전체 design philosophy는 세 문장으로 정리할 수 있다.

1. Optimize the actual decision space.

일반 language-model generation objective가 아니라 실제 competition에서 사용하는 `a/b/c/d` decision space를 직접 최적화한다.

2. Remember what remains surprising.

모델이 이미 잘 이해한 sample과 지속적으로 실패하는 sample을 동일하게 취급하지 않는다.

3. Spend inference compute only when necessary.

모든 sample에 고해상도·반복 reasoning을 수행하지 않고 uncertainty가 높은 sample에만 추가 computation을 제공한다.

이를 하나의 수식적 관점으로 표현하면 SSAFY-T의 목표는 단순한 empirical risk minimization을 넘어 다음과 같은 adaptive resource allocation 문제로 볼 수 있다.

$$\min_{\theta} \sum_i \pi_i^{\text{train}} L(x_i; \theta)$$

여기서 π_i^{train} 은 surprise에 따라 변화하는 effective training importance이다.

추론에서는 sample-dependent computation을

$$C_i = C_{\text{base}} + \mathbf{1}(M_i \leq \tau) C_{\text{extra}}$$

로 표현할 수 있다.

즉 training과 inference 모두 sample-specific difficulty에 따라 resource allocation이 달라진다.

45. Summary

SSAFY-T (Surprise-Sensitive Adaptive Framework for Your Answers with Titans)는 Qwen3-VL-2B-Instruct를 기반으로 하는 adaptive multiple-choice VQA framework이다.

기존 SSAFY가 language-model answer-token supervision과 direct logit inference를 결합한 baseline이었다면 SSAFY-T는 이를 다음 방향으로 확장한다.

```
Qwen3-VL-2B
+
4-bit QLoRA
+
Language LoRA
+
Direct 4-Choice CE
+
Hard-Negative Margin
+
Surprise Replay
+
Human/Teacher Pseudo Labels
+
Confidence Routing
+
High-Resolution Second Pass
↓
Adaptive Multiple-Choice VQA
```

Training 단계에서는 정답 choice와 가장 위험한 distractor를 직접 구분하도록 학습하며, 높은 CE loss를 지속적으로 보이는 sample을 surprise memory에 기록하여 추가 replay 한다.

Stage 2에서는 human consensus, teacher agreement, teacher margin이라는 세 개의 confidence signal을 동시에 만족하는 dev sample만 pseudo-labeled data로 추가 한다.

Inference에서는 모든 sample에 동일한 계산량을 배정하지 않는다. 첫 번째 저비용 inference의 confidence margin을 측정하고, 불확실한 sample에 대해서만 더 높은 resolution과 top-2 candidate-focused prompt를 이용한 second pass를 수행한다. 두 pass의 결과는 weighted log-probability fusion을 통해 통합한다.

따라서 SSAFY-T의 핵심은 특정 하나의 module에 있지 않다. 모델의 학습과 추론 전 과정에서 **현재 모델이 무엇을 어려워하고 있는지 측정하고, 그 어려움에 비례하여 추가적인 학습 또는 inference resource를 배정하는 것**이 핵심 architecture이다.

이를 가장 간결하게 표현하면 다음과 같다.

SSAFY-T learns more from what surprises it, and thinks more when it is uncertain.